INT1422 · KHO DỮ LIỆU VÀ KHAI PHÁ DỮ LIỆU

Kho dữ liệu chất lượng không khí Bắc Kinh & cảnh báo sớm PM2.5 vượt ngưỡng

420 768 giờ đo · 12 trạm · lược đồ hình sao 4 chiều · phân loại cảnh báo giờ tới

Nhóm [số nhóm] — [Họ tên 1 · MSSV] · [Họ tên 2 · MSSV] · [Họ tên 3 · MSSV]
Giảng viên: [Họ tên giảng viên] · Học viện Công nghệ Bưu chính Viễn thông

Câu hỏi: giờ tới có cần phát cảnh báo không?

"Giờ tới, tại trạm X, PM2.5 có ≥ 115 µg/m³ không?"

- **Ai dùng:** trung tâm quan trắc, trường học, bệnh viện
- **Quyết định:** cho/không cho hoạt động ngoài trời
- **Hiện tại:** chờ số đo vượt ngưỡng rồi mới báo, luôn trễ 1 giờ

79,8 µg/m³

PM2.5 trung bình 2013–2017 trên 12 trạm

≈ 1/4

số giờ có PM2.5 ≥ 115 µg/m³ (ngưỡng "ô nhiễm trung bình" theo AQI Trung Quốc)

0%

số lần bắt đầu đợt ô nhiễm mà cách làm hiện tại báo trước được

Dữ liệu: 420 768 giờ đo, nguồn mở, có giấy phép

420 768
bản ghi giờ

12
trạm quan trắc

4 năm
03/2013 – 02/2017

12
thuộc tính đo

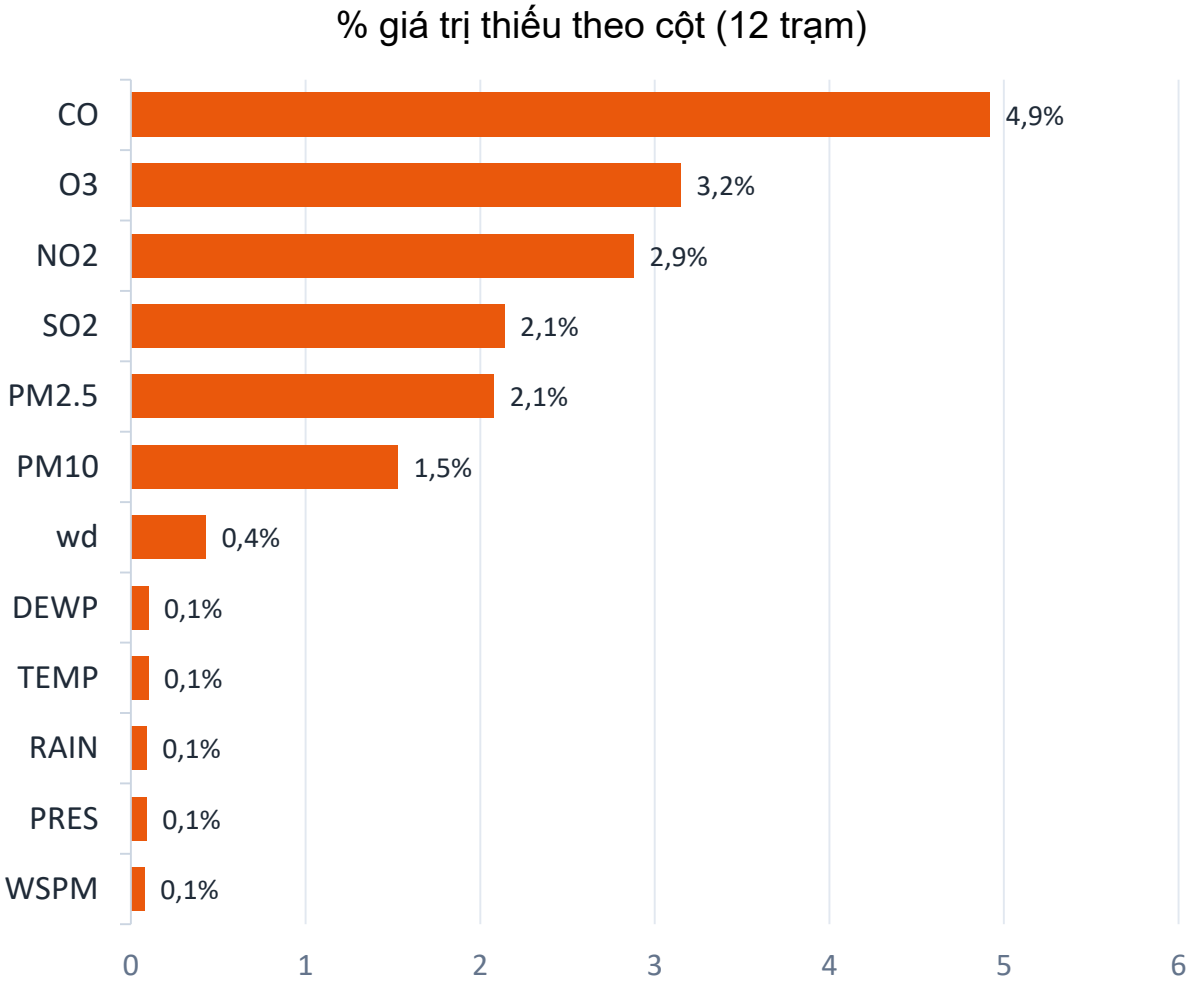
UCI Beijing Multi-Site Air Quality

- PM2.5, PM10, SO2, NO2, CO, O3 + 5 biến khí tượng + hướng gió
- Chen, S. (2017) · DOI 10.24432/C5RK5G
- **Giấy phép CC BY 4.0**

Open-Meteo Historical Weather

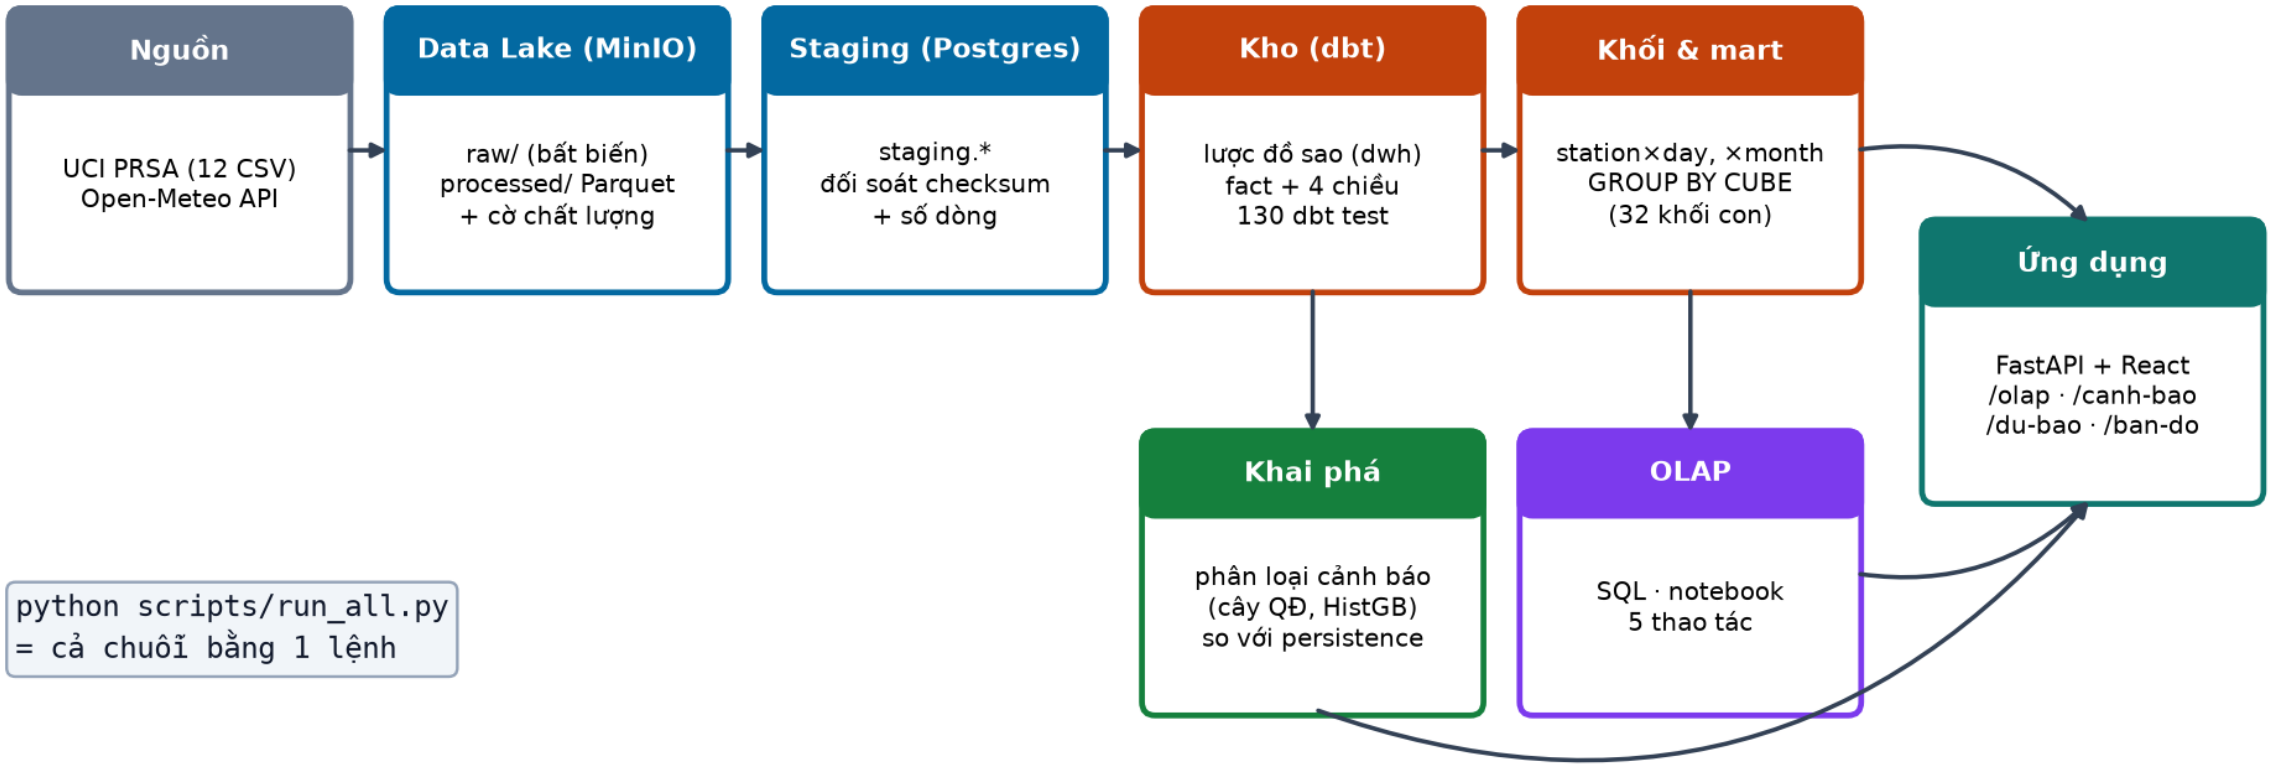
- Lấp chỗ thiếu thời tiết + thêm độ che phủ mây
- Tái phân tích ERA5, theo giờ, cùng 12 toạ độ
- **CC BY 4.0, phi thương mại**

Làm sạch: giữ NULL cho chất ô nhiễm, lấp thời tiết



- **Chất ô nhiễm:** giữ NULL + cờ chất lượng; chuỗi thiếu dài tới 343–1 517 giờ, không nội suy
- **Thời tiết, hướng gió:** lấp từ Open-Meteo, ghi nguồn; còn 0 ô thiếu
- **Trần thiết bị** (999, 10 000): giữ lại, gắn cờ SUSPECT_CAP (60 dòng)
- **Rời rạc hoá:** giờ → buổi · ngày → mùa · 16 hướng → 4 phần tư → bắc/nam

Toàn bộ chuỗi chạy lại được bằng một lệnh

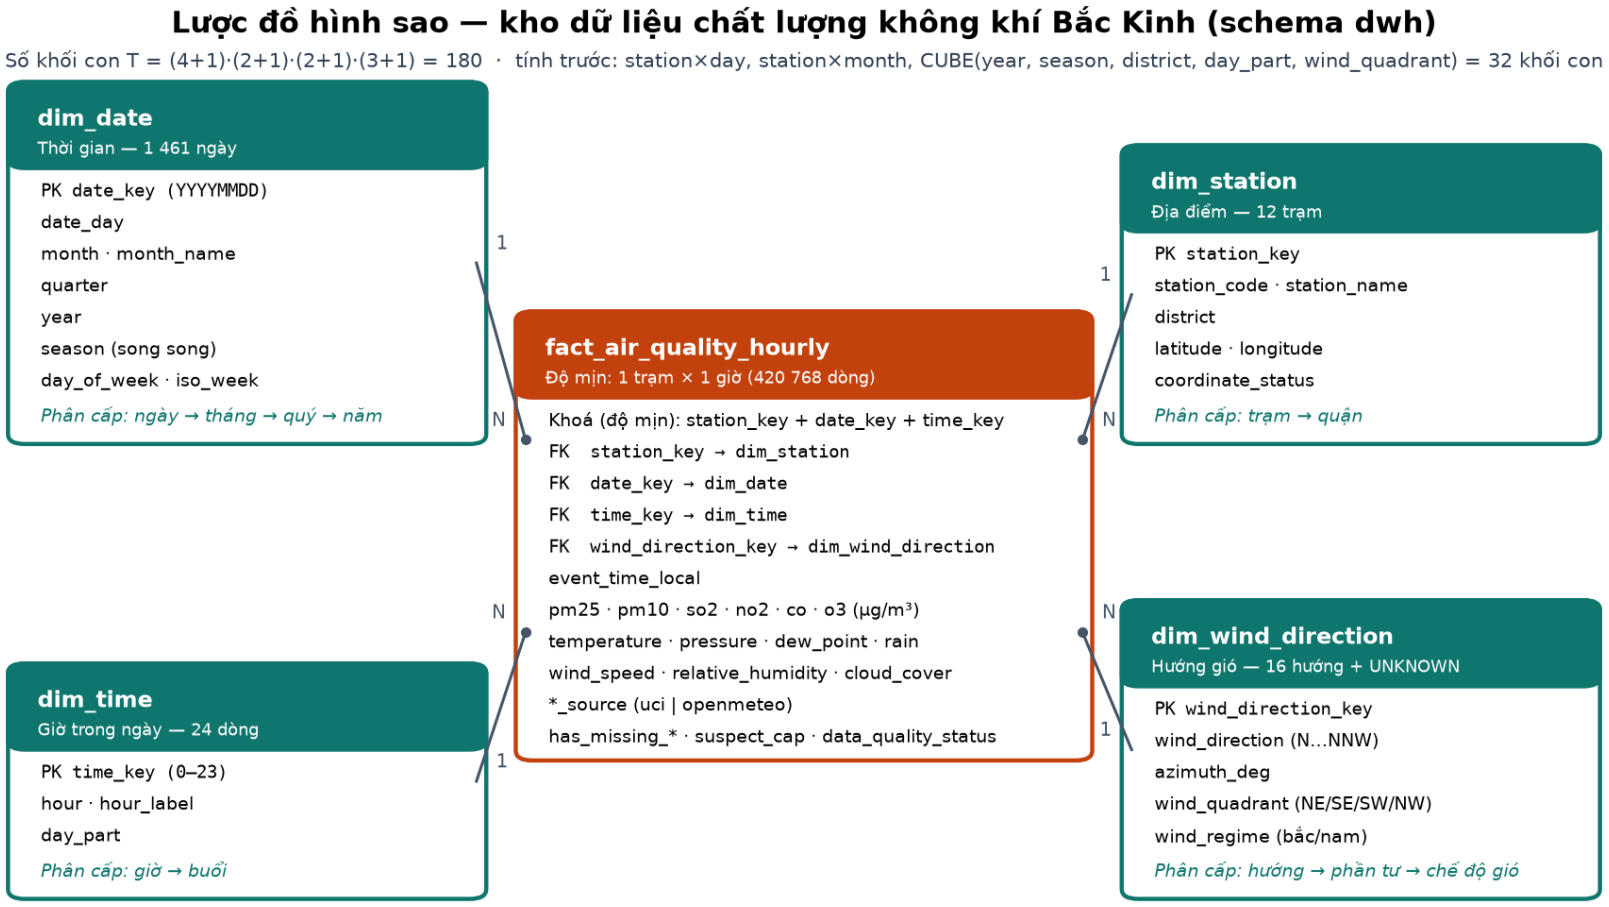



```
python scripts/run_all.py
= cả chuỗi bằng 1 lệnh
```

```
python scripts/run_all.py
```

14/14 bước · 11,2 phút từ trạng thái trống · 130/130 dbt test pass · idempotent

Lược đồ hình sao: độ mịn trạm × giờ, 4 chiều



- **Độ mịn trạm × giờ:** độ mịn gốc, cuộn lên được mọi mức
- **4 phân cấp:** ngày→tháng→quý→năm · giờ→buổi · trạm→quận · hướng→phần tư→bắc/nam
- **Số khối con:** T = 5·3·3·4 = 180

Ba khối tính trước, kiểm chứng 100% ô

Khối	Khối con	Số ô	Vì sao chọn
mart_station_daily	(trạm, ngày)	17 532	dashboard xu hướng; nhỏ hơn fact 24 lần
mart_station_monthly	(trạm, tháng)	576	báo cáo tháng/mùa; nhỏ hơn fact 730 lần
mart_olap_cube	CUBE(năm, mùa, quận, buổi, hướng gió)	6 075 · 32 khối	trang OLAP đọc trong vài ms

100%

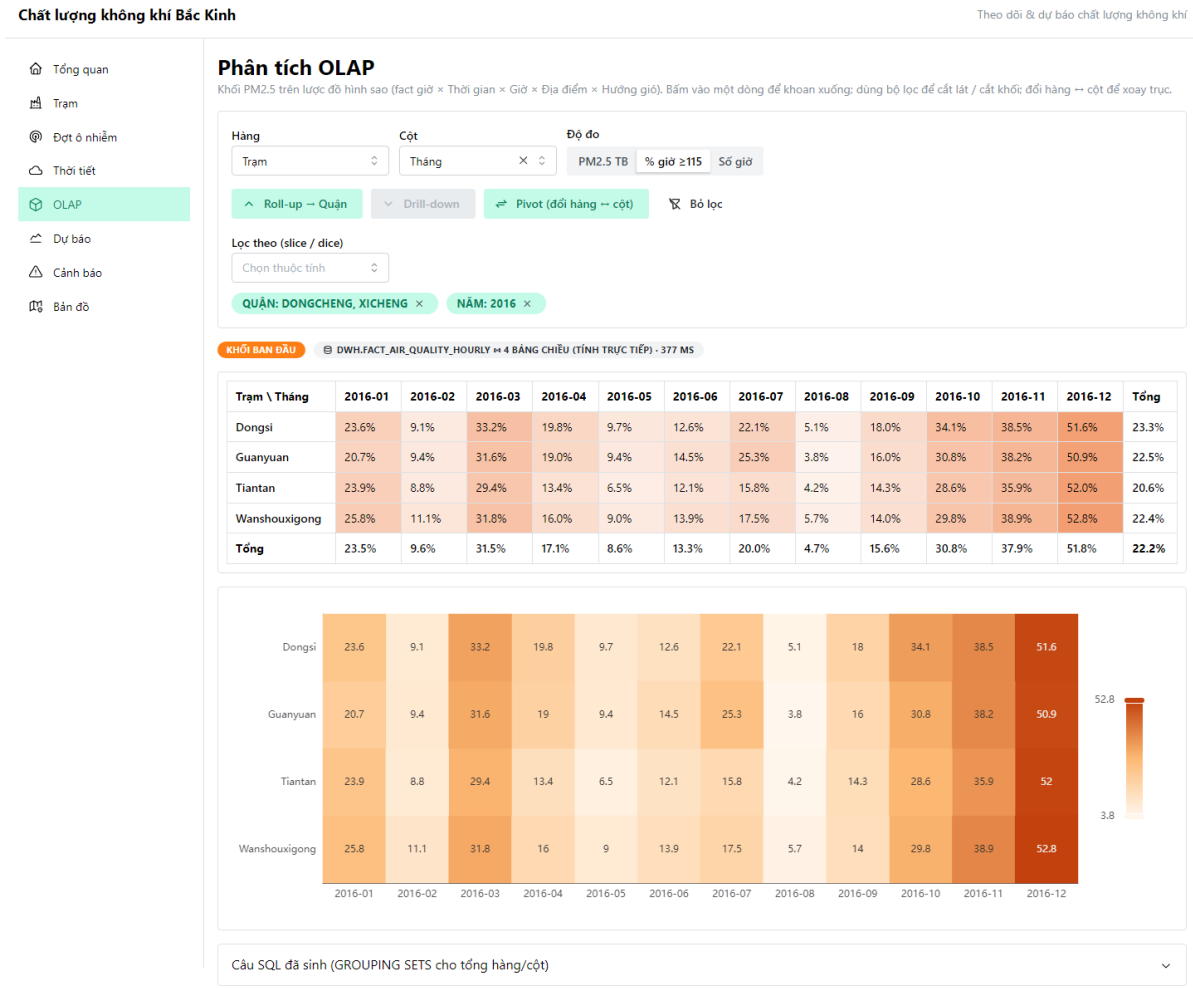
24.759/24.759 ô của 35 khối khớp khi tính lại từ fact

130/130

dbt test pass: khoá, độ mịn, khoá ngoại, cube phân hoạch fact

Truy vấn được viết lại theo khối: nếu mọi thuộc tính truy vấn nằm trong cube → đọc mart_olap_cube (2–6 ms), nếu không → quét fact (130–400 ms).

OLAP trực tiếp: roll-up, drill-down, slice, dice, pivot



1 **Roll-up**

tháng → quý → năm, trạm → quận

2 **Drill-down**

bấm một dòng để khoan xuống

3 **Slice**

một giá trị: quận = Dongcheng

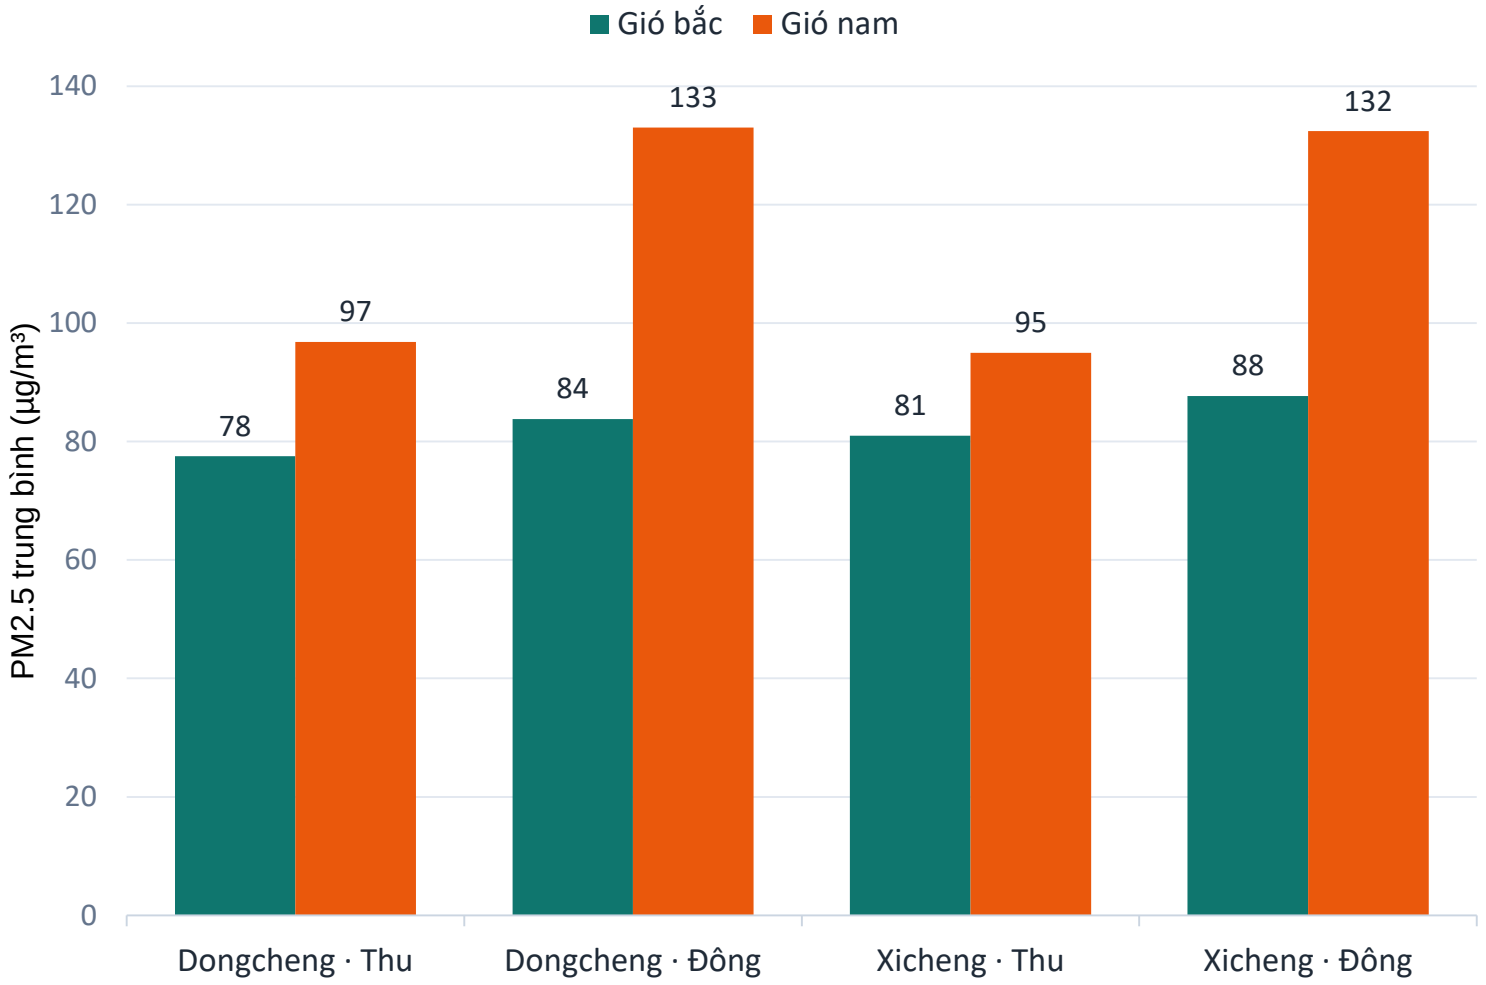
4 **Dice**

nhiều chiều: quận × năm × mùa

5 **Pivot**

đổi hàng ↔ cột

Dice cho thấy gió nam làm PM2.5 mùa đông tăng ~60%



84 → 133

µg/m³ — Dongcheng mùa đông, gió bắc → gió nam

- Tỷ lệ giờ vượt ngưỡng: ~28% → ~43%
- Hướng gió là chiều "vì sao" của kho
- → ưu tiên cảnh báo khi dự báo có gió nam

Phân loại: nhãn, đặc trưng, chia tập theo thời gian

train · 03/2013 – 12/2015

276.380 mẫu · 25% nhãn 1

val · 01–06/2016

47.338 mẫu · 16% nhãn 1

test · 07–12/2016

48.781 mẫu · 24% nhãn 1

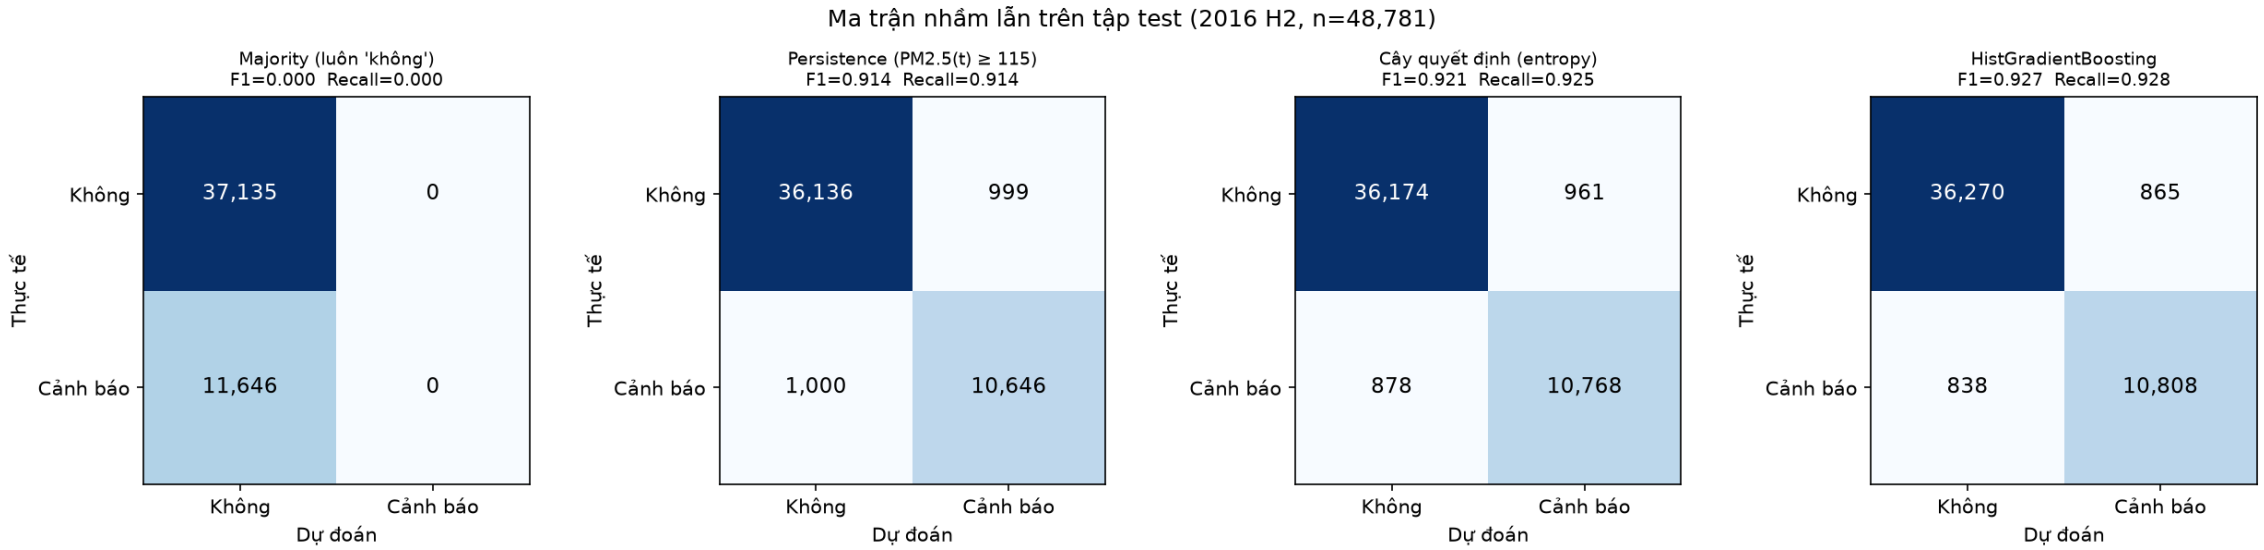
Nhãn & đặc trưng

- **y = 1** nếu PM2.5(t+1) ≥ 115 µg/m³
- PM2.5 hiện tại, độ trễ 1–24 giờ, xu hướng
- PM10, CO, NO2 · nhiệt độ, độ ẩm, gió
- giờ, tháng, mùa, trạm, cụm trạm

Mô hình

- **Cơ sở:** majority · persistence (cách hiện tại)
- **Cây quyết định** entropy, độ sâu 6 (chọn trên val)
- **HistGradientBoosting** ngưỡng 0,50
- Khoá mô hình có F1 trên val cao nhất

Mô hình bỏ sót ít hơn và báo nhầm ít hơn cách hiện tại



0,927

F1 của HistGB (persistence 0,914)

1.000 → 838

giờ ô nhiễm bị bỏ sót (FN)

999 → 865

cảnh báo nhầm (FP)

0,76

accuracy của majority — dù recall = 0

Báo trước được 30% số lần ô nhiễm bắt đầu

304 / 1.000

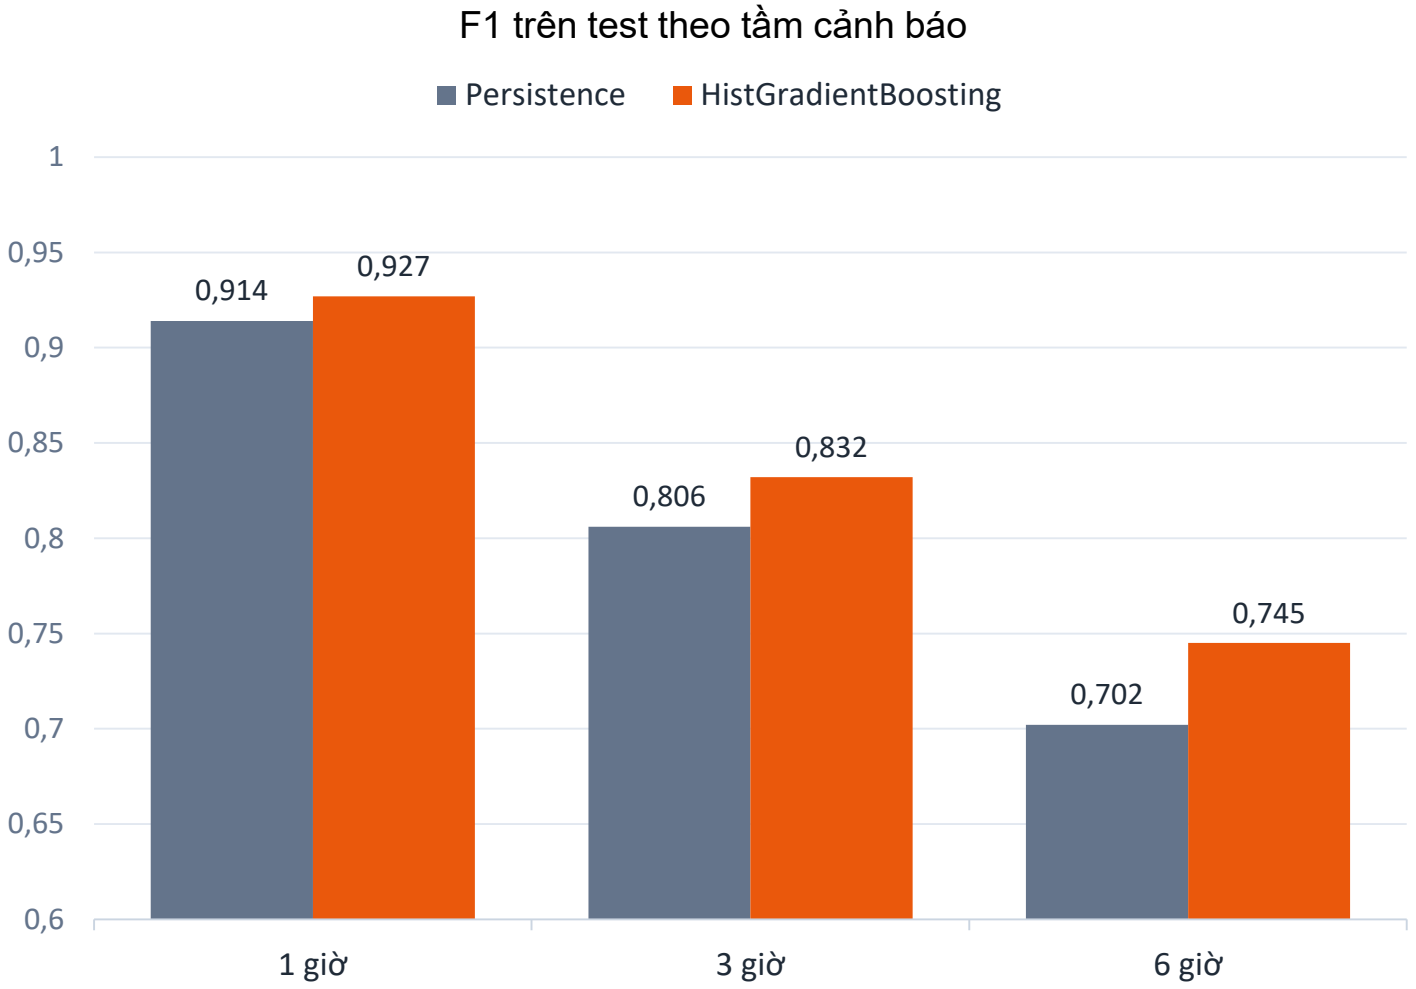
lần ô nhiễm bắt đầu được báo trước (persistence: 0)

$p = 5\times10^{-23}$

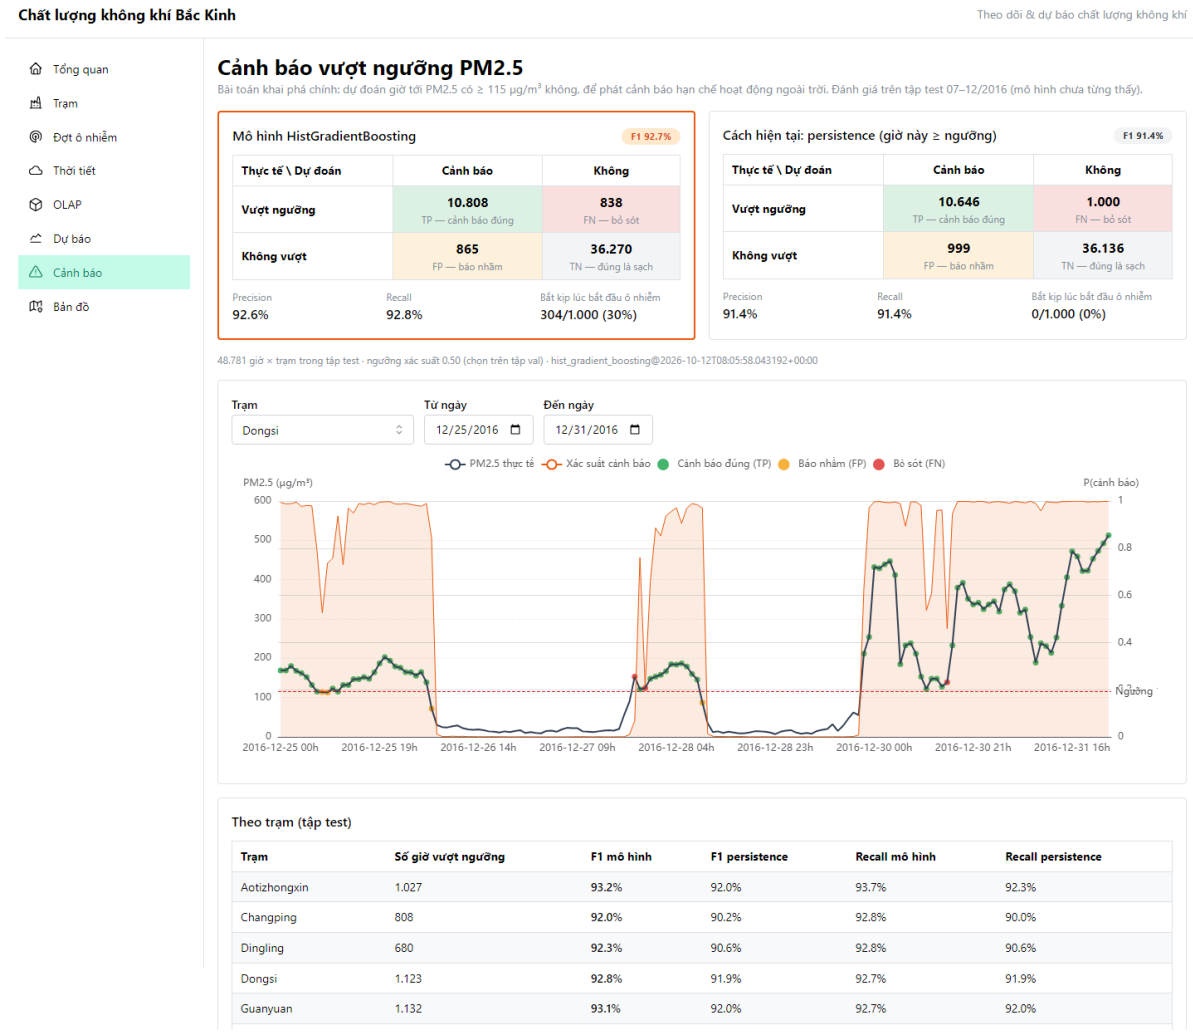
McNemar: 594 giờ chỉ mô hình đúng, 298 giờ chỉ persistence đúng

12/12

trạm có F1 cao hơn persistence



Ứng dụng: trang Cảnh báo cho người vận hành



- Ma trận nhầm lẫn: mô hình so với cách hiện tại
- Dòng thời gian xác suất theo trạm
- Đọc từ mart_pm25_alerts (dbt)
- Cùng app: /olap, /du-bao, /ban-do

Khuyến nghị hành động và hạn chế

Nên làm

- Cảnh báo theo xác suất của mô hình, không chờ số đo vượt ngưỡng
- Ưu tiên mùa đông, buổi tối/đêm, khi có gió nam
- Cần báo sớm 3–6 giờ: chấp nhận thêm báo nhầm để đổi lấy recall cao

Hạn chế

- Test chỉ 6 tháng cuối 2016, dữ liệu lịch sử
- Tầm 1 giờ còn ngắn cho quyết định lớn
- Lợi thế so với persistence khiêm tốn (+0,013 F1 ở 1 giờ)
- Ngưỡng 115 là ngưỡng 24 giờ, áp cho từng giờ

0,927 vs 0,914

F1 mô hình so với cách hiện tại (test)

30%

số lần ô nhiễm bắt đầu được báo trước

100%

ô khối tính trước kiểm chứng đúng

Cảm ơn thầy/cô và các bạn

Hỏi đáp

Mã nguồn + hướng dẫn chạy: README.md · python scripts/run_all.py
Báo cáo: bao_cao/BaoCao_BTL_INT1422.docx · Phân công & khai báo AI: bao_cao/

[Thành viên 1 — phần …] [Thành viên 2 — phần …] [Thành viên 3 — phần …]